
Validación numérica independiente de ADR1D-ML y ADR1D-NN

Informe técnico reproducible

Gerardo Tinoco-Guerrero
Francisco J. Domínguez-Mota
J. Alberto Guzmán-Torres

Universidad Michoacana de San Nicolás de Hidalgo
Morelia, Michoacán, México

Contacto: gerardo.tinoco@umich.mx

Identificador del protocolo: ADR1D-NUMERICAL-VALIDATION v1.0.0
Versión del informe: 1.1, revisión explicativa
Periodo programado de desarrollo: mayo–junio de 2025
Última actualización: julio de 2026
Fecha de bloqueo: 21 de julio de 2026

21 de julio de 2026

Resumen

Este informe examina dos tareas de transporte reactivo unidimensional. En la primera, ADR1D-ML estima propiedades efectivas a partir de seis historias de sensores con ruido. En la segunda, ADR1D-NN calcula la concentración dividida entre la concentración de entrada cuando esas propiedades ya se conocen. Los modelos y sus umbrales se congelaron antes de construir un desafío de 120 escenarios nuevos dentro del dominio ADR1D. Cada escenario inverso tuvo cinco realizaciones de ruido; la prueba del campo neuronal reunió 299,880 pares de posición y tiempo. El protocolo fijó previamente muestras, métricas, tolerancias y semillas. Como comprobación adicional, 16 escenarios se resolvieron con volúmenes finitos en tres mallas y se compararon con la solución analítica. El costo se midió por componente en un hilo de CPU.

ADR1D-ML cumplió los criterios preespecificados. La mediana del error relativo absoluto fue 3.95 % para velocidad efectiva y 24.94 % para dispersión efectiva. La clasificación de si el decaimiento podía distinguirse del ruido obtuvo exactitud balanceada de 0.8357 y área bajo la curva característica operativa del receptor (ROC) de 0.9113; sin embargo, 15 de 34 declaraciones positivas fueron falsos positivos. ADR1D-NN obtuvo una raíz del error cuadrático medio (RMSE) global de 0.02258 en la escala normalizada y $R^2 = 0.98937$. No produjo valores fuera de $[0, 1]$ y respetó exactamente las condiciones que su interfaz impone por construcción. El promedio favorable coexistió con errores localizados: en el peor punto la referencia era cero al encender la fuente en la primera posición interior y la red predijo 0.74945.

La solución de volúmenes finitos redujo su error al refinar en los 16 casos y cada malla fina quedó dentro de la tolerancia analítica. Dos casos con $Pe = 350$ rebasaron en 6.9 % y 7.4 % la tolerancia entre las mallas media y fina; por ello, la evidencia numérica se conserva como mixta. La solución analítica fue la carga de campo más rápida y las tareas cronometradas no son equivalentes, de modo que no se afirma una aceleración universal. Los modelos pueden integrarse en experimentos controlados dentro de ADR1D, pero se validaron por separado: el campo neuronal recibió parámetros verdaderos, no los estimados por ADR1D-ML. El estudio no demuestra desempeño del flujo encadenado, validación de campo, extrapolación ni aptitud regulatoria.

Palabras clave: transporte de contaminantes; aprendizaje automático; red neuronal; validación numérica; solución analítica; volúmenes finitos; reproducibilidad.

Índice

1. Propósito y alcance	3
1.1. Guía de lectura y vocabulario	3
2. Problema físico y artefactos evaluados	4
2.1. Ecuación de transporte	4
2.2. Modelos congelados	6
3. Diseño de validación	7
3.1. Bloqueo previo y separación de evidencia	7
3.2. Conjunto de desafío	8
3.3. Métricas y análisis estadístico	9
3.4. Referencia numérica tradicional	11
3.5. Costo computacional	12
4. Resultados	13
4.1. Reproducción e integridad	13
4.2. Estimación de parámetros con ADR1D-ML	13
4.3. Predicción de campos con ADR1D-NN	15
4.4. Referencia numérica y refinamiento	17
4.5. Costo computacional	19
5. Discusión	20
5.1. Qué demuestra la evaluación	20
5.2. Lectura conjunta de los modelos	21
5.3. Qué no demuestra	21
5.4. Implicaciones para integración numérica	22
6. Amenazas a la validez y limitaciones	23
7. Reproducibilidad y trazabilidad	23
8. Conclusiones	24
Declaraciones	25

1. Propósito y alcance

El transporte de una sustancia disuelta en el subsuelo puede estudiarse desde dos direcciones complementarias. En el *problema directo* se conocen las propiedades del transporte y se calcula cómo cambia la concentración en el espacio y el tiempo. En el *problema inverso* se observan curvas de concentración y se intenta recuperar las propiedades que las originaron. En ambos casos, una predicción agregada favorable puede ocultar errores locales: por ejemplo, un frente puede llegar antes de tiempo aunque el promedio del campo sea cercano a la referencia.

La finalidad de este estudio es determinar, con evidencia verificable, qué afirmaciones pueden sostenerse acerca de dos modelos que representan esas dos direcciones. ADR1D-ML resuelve el problema inverso y ADR1D-NN aproxima el problema directo. Ambos fueron desarrollados sobre ADR1D versión 1.0.0, un conjunto sintético de referencia (benchmark) de transporte reactivo unidimensional con parámetros constantes por escenario [1]. Sus funciones son distintas:

- **ADR1D-ML** recibe seis historias temporales de sensores con ruido. A partir de ellas estima velocidad efectiva, dispersión efectiva, si el decaimiento puede distinguirse del nivel de ruido y, únicamente cuando esa distinción es físicamente resoluble, una tasa de decaimiento [2].
- **ADR1D-NN** recibe una posición, un tiempo, los parámetros efectivos y la definición temporal de la fuente. Devuelve la concentración dividida entre la concentración de entrada, es decir, un valor adimensional del campo en ese punto [3].

Esta diferencia impide interpretar sus métricas o tiempos como una competencia entre modelos: uno produce parámetros por escenario y el otro produce valores de concentración por punto. El objetivo es verificar por separado precisión, consistencia física, sensibilidad a regímenes, reproducibilidad y costo bajo contratos de entrada definidos. La palabra *independiente* se refiere aquí a que el protocolo se fijó antes de observar el desafío, los modelos quedaron congelados, las muestras nuevas no se usaron para entrenar y la auditoría se realizó desde archivos persistidos. No significa que se haya usado una teoría física distinta: el desafío conserva la ecuación y los intervalos de ADR1D.

Tampoco se pretende reemplazar una evaluación hidrogeológica de sitio, demostrar comportamiento fuera de los rangos de entrenamiento ni atribuir a los registros observacionales del Water Quality Portal variables hidráulicas que no contienen. Las conclusiones se limitan al problema sintético definido en este documento.

Las preguntas de validación fueron las siguientes:

1. ¿Se reproducen los resultados canónicos publicados sin modificar los modelos ni sus protocolos?
2. ¿Mantienen ambos modelos un desempeño aceptable en escenarios nuevos, generados antes de la inferencia y sin colisiones con el conjunto canónico?
3. ¿Dónde se concentran los errores y qué diferencias aparecen entre regímenes físicos, perfiles interiores y perfiles de frontera?
4. ¿La referencia analítica concuerda con una discretización tradicional independiente al refinar espacio y tiempo?
5. ¿Cuál es el costo observado de cada componente bajo una política de medición explícita y reproducible?

1.1. Guía de lectura y vocabulario

El informe separa deliberadamente la referencia física, los datos de entrada, las consultas a los modelos y los diagnósticos posteriores. La Tabla 1 resume términos que se repiten a lo largo del

texto.

Tabla 1: Vocabulario operativo utilizado en la validación.

Término	Significado en este informe
Escenario base	Una combinación completa de parámetros físicos y de la fuente. Es la unidad independiente de análisis.
Realización de ruido	Una observación sintética diferente del mismo escenario; solo cambia el ruido de los sensores.
Punto espacio-temporal	Un par (x, t) dentro de un escenario. Los puntos de una misma malla están correlacionados y no se cuentan como experimentos independientes.
Referencia analítica	Valor calculado con la solución cerrada de ADR1D para los parámetros verdaderos del escenario.
Referencia tradicional	Solución obtenida con el método independiente de volúmenes finitos descrito en la Sección 3.4.
Modelo congelado	Archivo de modelo identificado y bloqueado antes del desafío, sin posibilidad de reentrenamiento o ajuste posterior.
Región activa	Puntos cuya concentración normalizada de referencia es mayor que 10^{-4} .
Criterio preespecificado	Tolerancia registrada antes de la inferencia. Su incumplimiento se conserva; no desencadena un cambio del umbral o del modelo.

2. Problema físico y artefactos evaluados

2.1. Ecuación de transporte

ADR1D representa transporte en un medio homogéneo mediante

$$R \frac{\partial C}{\partial t} = D \frac{\partial^2 C}{\partial x^2} - v \frac{\partial C}{\partial x} - \lambda RC, \quad (1)$$

donde C es la concentración disuelta, D la dispersión longitudinal, v la velocidad advectiva, R el factor de retardación y λ la tasa de decaimiento de primer orden. La coordenada x aumenta en la dirección media del flujo y t representa el tiempo transcurrido desde el inicio del experimento. La Tabla 2 reúne unidades e interpretación.

Tabla 2: Variables y parámetros de la ecuación de transporte.

Símbolo	Unidad	Interpretación
$C(x, t)$	mg L^{-1}	Concentración disuelta en la posición x y el tiempo t .
v	m s^{-1}	Velocidad advectiva antes de aplicar el efecto de retardación. Desplaza el centro del pulso.
D	$\text{m}^2 \text{s}^{-1}$	Coefficiente de dispersión longitudinal. Controla el ensanchamiento del frente y de la cola.
R	Adimensional	Factor de retardación. Un valor mayor que uno reduce la velocidad y la dispersión efectivas del soluto respecto del flujo de referencia.
λ	s^{-1}	Tasa de pérdida de primer orden. En ausencia de transporte, la concentración decrece como $\exp(-\lambda t)$.
C_0	mg L^{-1}	Concentración prescrita en la entrada mientras la fuente permanece encendida.
t_0, τ	s	Instante de encendido y duración del pulso de entrada.

Los tres términos del lado derecho de la Ecuación (1) tienen funciones distintas. El término con segunda derivada suaviza gradientes por dispersión; el término con primera derivada transporta el perfil; y $-\lambda RC$ reduce la concentración. Después de dividir entre R se definen $D_{\text{eff}} = D/R$ y $v_{\text{eff}} = v/R$:

$$\frac{\partial C}{\partial t} = D_{\text{eff}} \frac{\partial^2 C}{\partial x^2} - v_{\text{eff}} \frac{\partial C}{\partial x} - \lambda C. \quad (2)$$

Esta escritura muestra qué parámetros reciben los modelos: ADR1D-ML intenta recuperar v_{eff} y D_{eff} , mientras que ADR1D-NN los recibe como entradas conocidas. El decaimiento conserva la tasa λ porque el factor R aparece tanto en el término temporal como en el término de reacción de la Ecuación (1).

Para comparar escenarios con distintas concentraciones de fuente se utiliza

$$c(x, t) = \frac{C(x, t)}{C_0}. \quad (3)$$

La variable c es adimensional. En el benchmark toma como referencia cero antes de la llegada y uno en la entrada durante el pulso. Un RMSE de 0.02 en este campo equivale, por tanto, a un error cuadrático medio de dos puntos porcentuales respecto de C_0 ; no equivale a 0.02 mg L⁻¹ salvo que $C_0 = 1$ mg L⁻¹.

La condición inicial es $C(x, 0) = 0$. En $x = 0$ se prescribe un pulso rectangular,

$$C(0, t) = \begin{cases} C_0, & t_0 \leq t < t_0 + \tau, \\ 0, & \text{en otro caso,} \end{cases} \quad (4)$$

y la solución analítica supone decaimiento en el campo lejano. ADR1D evalúa una extensión reactiva de la respuesta tipo Ogata–Banks [4, 5]. Si $u = (v^2 + 4\lambda RD)^{1/2}$, la respuesta unitaria de escalón es

$$S(x, t) = \frac{1}{2} \exp\left(\frac{(v-u)x}{2D}\right) \text{erfc}\left(\frac{Rx - ut}{2\sqrt{DRt}}\right) + \frac{1}{2} \exp\left(\frac{(v+u)x}{2D}\right) \text{erfc}\left(\frac{Rx + ut}{2\sqrt{DRt}}\right), \quad (5)$$

para $t > 0$, y el pulso se obtiene como $C(x, t) = C_0[S(x, t - t_0) - S(x, t - t_0 - \tau)]$. Esta expresión evita asociar las etiquetas de referencia con el error de una malla numérica particular. La función erfc es la función error complementaria. Cuando el tiempo transcurrido que recibe S es menor o igual que cero, la respuesta se define como cero. La resta de dos escalones tiene una interpretación sencilla: el primero enciende la fuente en t_0 y el segundo retira, después de τ , la contribución de una fuente que habría permanecido activa.

La solución cerrada se formula sobre un dominio semiinfinito. El benchmark retiene los primeros $L = 1000$ m y las primeras 24 h. La referencia de volúmenes finitos, que sí necesita una frontera de salida, extiende el dominio hasta 1200 m y evita comparar cerca de esa salida; esta diferencia se detalla en la Sección 3.4.

Para interpretar los extremos del diseño se utilizan

$$\text{Pe} = \frac{v_{\text{eff}} L}{D_{\text{eff}}}, \quad \text{Da} = \frac{\lambda L}{v_{\text{eff}}}, \quad (6)$$

con $L = 1000$ m. Los cuatro regímenes combinan retardación activa o inactiva y decaimiento activo o nulo: conservativo, solo decaimiento, solo retardación, y retardación con decaimiento. El número de Peclet compara advección y dispersión: valores altos corresponden a frentes más estrechos y dominados por transporte advectivo; valores bajos corresponden a perfiles más difundidos. El número de Damköhler compara la escala de decaimiento con el tiempo de viaje advectivo: $Da = 0$ indica ausencia de decaimiento y valores mayores implican una atenuación más visible durante el recorrido de longitud L .

Tabla 3: Regímenes físicos del diseño. “Activo” significa que el parámetro se muestrea en su intervalo; “inactivo” fija $R = 1$ o $\lambda = 0$.

Régimen	Retardación	Decaimiento	Lectura física
Conservativo	Inactiva	Inactivo	Transporte sin pérdida reactiva y sin reducción adicional por retardación.
Solo decaimiento	Inactiva	Activo	Atenuación de primer orden durante el transporte.
Solo retardación	Activa	Inactivo	Menor velocidad y dispersión efectivas, sin pérdida de masa por reacción.
Retardación y decaimiento	Activa	Activo	Acción simultánea de retraso y atenuación.

2.2. Modelos congelados

Los artefactos se trataron como cajas cerradas con interfaces públicas. El paquete serializado (bundle) de ADR1D-ML y el archivo de pesos y transformaciones (checkpoint) de ADR1D-NN quedaron identificados en sus manifiestos y registros de bloqueo antes del desafío. Su integridad se verificó antes y después de cada operación que cargó un modelo. No se permitió reentrenamiento, selección adicional de hiperparámetros, cambio del umbral de clasificación ni corrección posterior a los resultados de desafío.

2.2.1. Flujo inverso de ADR1D-ML

Cada realización que entra a ADR1D-ML contiene 294 observaciones: 49 tiempos en cada uno de seis sensores. La interfaz no entrega directamente esas 294 concentraciones a un único estimador. Primero resume cada sensor mediante once descriptores: fracción detectada, cociente del pico respecto de C_0 , tiempo del pico, primera y última detección, área normalizada, centroide, dispersión temporal y tiempos acumulados del 10, 50 y 90 % del área. Los 66 descriptores de sensores, junto con C_0 , t_0 y τ , forman 69 características por realización.

La estimación de velocidad y dispersión utiliza dos ensambles independientes de 300 árboles extremadamente aleatorizados. Ambos predicen el logaritmo base diez del parámetro positivo y aplican imputación por mediana cuando un descriptor temporal no puede calcularse, por ejemplo, porque un sensor no registra señal por encima del límite de detección. La transformación logarítmica permite tratar errores multiplicativos y evita predicciones físicas negativas al volver a unidades originales.

La clasificación de decaimiento añade 17 descriptores que comparan sensores a distintas distancias. Incluyen pendientes de picos, áreas, centroides y tiempos, calidad de esos ajustes y aproximaciones físicas de velocidad, dispersión y atenuación. Una regresión logística con 86 entradas estima la probabilidad de que el decaimiento sea resoluble. La verdad de clasificación se definió antes del entrenamiento mediante

$$a_\lambda = 1 - \exp(-\text{Da}), \quad y_{\text{res}} = \mathbb{I}(a_\lambda \geq 0.03), \quad (7)$$

de modo que el umbral físico equivale a $\text{Da} \geq -\ln(0.97) = 0.0304592$. En palabras, el decaimiento se etiqueta como resoluble cuando su atenuación ideal durante un tiempo de viaje alcanza al menos el ruido relativo de 3, %. Esta etiqueta expresa capacidad de resolución en el benchmark; no equivale a presencia o ausencia química de una reacción. Una tasa positiva por debajo del umbral se considera no resoluble con estos sensores y este nivel de ruido.

La probabilidad se convierte en clase positiva cuando es mayor o igual que 0.19, umbral seleccionado durante el desarrollo y congelado antes de la prueba. Solo para escenarios cuya verdad satisface la Ecuación (7), un cuarto modelo de 300 árboles estima $\log_{10} \lambda$ a partir de doce descriptores seleccionados. Esta separación evita presentar una estimación numérica de λ cuando el efecto esperado queda por debajo de la resolución definida.

Las cinco realizaciones de ruido producen cinco predicciones por escenario. Si $\hat{z}_r > 0$ denota una predicción positiva de la réplica r , su resumen es la media geométrica

$$\hat{z}_{\text{esc}} = \exp\left(\frac{1}{5} \sum_{r=1}^5 \ln \hat{z}_r\right). \quad (8)$$

Las probabilidades se promedian aritméticamente y el umbral 0.19 se aplica una sola vez al promedio. Así, cada escenario aporta una observación a las métricas principales, mientras que la variación entre réplicas se conserva como diagnóstico de sensibilidad al ruido.

2.2.2. Flujo directo de ADR1D-NN

ADR1D-NN es un modelo sustituto neuronal condicionado por coordenadas y parámetros. Su interfaz recibe nueve columnas: x , t , L , el tiempo final, v_{eff} , D_{eff} , λ , t_0 y τ . A partir de ellas construye siete entradas para la red: posición y tiempo normalizados, logaritmos de velocidad y dispersión efectivas, una transformación $\log(1 + \lambda/10^{-6})$, inicio de fuente normalizado y duración normalizada. Las medias y desviaciones utilizadas para estandarizar estas entradas están almacenadas en el checkpoint.

La red es un perceptrón multicapa con tres capas ocultas de 128 neuronas, activación SiLU, salida sigmoide y 34,177 parámetros entrenables. El checkpoint corresponde a la época 57, seleccionada con el conjunto de validación durante el desarrollo. La salida sigmoide mantiene la predicción neuronal entre cero y uno. Como la Ecuación (2) es lineal respecto de la concentración, C_0 no es una entrada de la red: para recuperar unidades dimensionales se calcula $\hat{C} = C_0 \hat{c}$.

La interfaz reemplaza la salida de la red por valores exactos en dos conjuntos: $c(x, 0) = 0$ para $x > 0$, y el pulso rectangular en $x = 0$. El orden de aplicación resuelve además la esquina $(0, 0)$ según la condición de entrada. En los puntos interiores restantes, incluidos los instantes cercanos al encendido y apagado, la predicción procede de la red. En consecuencia, satisfacer esas dos condiciones comprueba el contrato implementado, pero no demuestra por sí solo conservación local ni satisfacción exacta de la ecuación diferencial.

3. Diseño de validación

3.1. Bloqueo previo y separación de evidencia

El protocolo, sus entradas y las tolerancias quedaron bloqueados antes de generar casos o ejecutar inferencia nueva. El registro inicial verificó 18 entradas congeladas y dejó en cero los contadores

de escenarios nuevos, inferencias de desafío y soluciones tradicionales. Después se siguieron tres niveles de evidencia:

1. **Reproducción canónica.** Se repitieron las pruebas ya publicadas de 45 escenarios, sin utilizar el desafío.
2. **Desafío independiente.** Se generaron, verificaron y bloquearon 120 escenarios antes de una única inferencia persistida por modelo.
3. **Referencia numérica tradicional.** Se eligieron 16 escenarios solo con parámetros verdaderos y se resolvieron en tres niveles de malla.

La secuencia operativa fue: (1) registrar protocolo, modelos, código y datos canónicos; (2) generar el conjunto nuevo sin cargar modelos; (3) reconstruirlo con un validador separado; (4) bloquear el conjunto y sus registros; (5) preparar las tablas de entrada sin inferencia; (6) ejecutar una consulta persistida por modelo; y (7) recalcular las métricas desde los CSV mediante un auditor que no importa el evaluador ni deserializa los modelos. La referencia tradicional se ejecutó después, con escenarios elegidos únicamente a partir de parámetros verdaderos.

Esta secuencia evita dos formas de optimismo. Primero, impide seleccionar casos después de conocer dónde funcionan mejor los modelos. Segundo, impide cambiar un umbral o una transformación para mejorar retrospectivamente el resultado. Las métricas nuevas no se emplearon para modificar los modelos. El resultado de un criterio incumplido debía conservarse y discutirse con el mismo detalle que un resultado favorable.

3.2. Conjunto de desafío

El diseño incluyó 30 escenarios por régimen: 24 puntos interiores obtenidos con muestreo por hipercubo latino (Latin hypercube) [6] y seis perfiles de frontera. La Tabla 4 resume los intervalos. Las variables positivas que cubren varios órdenes se muestrearon en escala logarítmica; las demás, en escala lineal. En el muestreo por hipercubo latino cada intervalo transformado se divide en 24 estratos y cada estrato se usa una vez por dimensión. Esto mejora la cobertura del intervalo con menos puntos que una cuadrícula cartesiana, pero no convierte los escenarios en una muestra de frecuencias naturales de un acuífero.

Tabla 4: Rangos del conjunto de desafío bloqueado.

Variable	Intervalo	Transformación de diseño
Velocidad v	0.05–0.35 m s ⁻¹	Lineal
Dispersión D	1–20 m ² s ⁻¹	log ₁₀
Concentración de fuente C_0	0.2–5 mg L ⁻¹	log ₁₀
Inicio de fuente t_0	0–3600 s	Lineal
Duración τ	1800–10800 s	Lineal
Retardación activa R	1.1–3.0	Lineal
Decaimiento activo λ	10^{-7} – 2×10^{-5} s ⁻¹	log ₁₀

Los seis perfiles de frontera por régimen no son observaciones aleatorias. Los primeros cuatro combinan los valores mínimo y máximo de velocidad y dispersión, manteniendo las demás coordenadas transformadas en su punto medio. Los dos restantes combinan extremos opuestos de concentración, inicio, duración, retardación y decaimiento. Su propósito es exponer al modelo a esquinas documentadas del dominio que el muestreo interior abierto no toca exactamente. Cuando un proceso está inactivo en un régimen se fija $R = 1$ o $\lambda = 0$.

La red neuronal recibe parámetros efectivos. Debido a la división entre R , el intervalo efectivo cubierto es aproximadamente $0.0167\text{--}0.35 \text{ m s}^{-1}$ para velocidad y $0.333\text{--}20 \text{ m}^2 \text{ s}^{-1}$ para dispersión. Todos los casos del desafío permanecen dentro de los contratos estrictos de ADR1D-ML y ADR1D-NN; los perfiles de frontera prueban extremos permitidos, no extrapolación.

El campo de cada escenario contiene 51 posiciones entre 0 y 1000 m y 49 tiempos entre 0 y 86400 s, para un total de 299,880 valores. ADR1D-ML utilizó seis sensores en 100, 250, 400, 600, 800 y 1000 m. Cada escenario recibió cinco realizaciones independientes de ruido gaussiano relativo de 3 %, piso absoluto de 0.002 mg L^{-1} , límite de detección de 0.01 mg L^{-1} y sustitución de 0.005 mg L^{-1} por debajo del límite. Esto produjo 600 realizaciones y 176,400 observaciones.

En cada observación con verdad C_{ref} se utilizó

$$\sigma(C_{\text{ref}}) = \text{máx}\left(0.002 \text{ mg L}^{-1}, 0.03C_{\text{ref}}\right), \quad (9)$$

$$C_{\text{sin censura}} = \text{máx}(0, C_{\text{ref}} + \sigma Z), \quad Z \sim \mathcal{N}(0, 1). \quad (10)$$

Si $C_{\text{sin censura}} < 0.01 \text{ mg L}^{-1}$, el valor entregado al flujo de características fue 0.005 mg L^{-1} y se marcó como no detectado. Durante la extracción, esa marca conserva la frecuencia de no detecciones, pero asigna cero a la señal integrada. Esta convención separa el valor utilizado para representar un reporte bajo el límite de detección del valor utilizado para calcular área, centroide y tiempos acumulados.

La semilla de parámetros fue 2026072105; la de ruido, 2026072106; y la de bootstrap, 2026072107. El validador reconstruyó los escenarios, los campos, las concentraciones verdaderas y cada secuencia de ruido sin cargar los modelos. La diferencia absoluta máxima frente a la reconstrucción fue aproximadamente $5.0 \times 10^{-12} \text{ mg L}^{-1}$. No hubo identificadores o parámetros duplicados respecto de los 300 escenarios canónicos; la distancia normalizada mínima fue 0.1170. Una segunda generación temporal produjo archivos idénticos byte por byte. La distancia se calculó después de llevar cada parámetro a su coordenada lineal o logarítmica normalizada. Por tanto, 0.1170 indica separación en el espacio de diseño; no es una distancia física en metros ni una medida de similitud entre campos completos.

3.3. Métricas y análisis estadístico

3.3.1. Errores de regresión y de campo

Sea y_i una referencia, $\hat{y}_i$ su predicción y $e_i = \hat{y}_i - y_i$. Las métricas básicas se calcularon como

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |e_i|, \quad (11)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N e_i^2}, \quad (12)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N e_i^2}{\sum_{i=1}^N (y_i - \bar{y})^2}. \quad (13)$$

El error absoluto medio (MAE) expresa el tamaño medio del error sin distinguir signo. La raíz del error cuadrático medio (RMSE) asigna más peso a errores grandes porque eleva los residuos al cuadrado. El coeficiente R^2 compara el error del modelo con el de predecir siempre la media de las referencias: uno indica acuerdo perfecto; cero, que no mejora esa media; y un valor negativo, que la empeora. Un R^2 alto no garantiza un error máximo pequeño ni una llegada correcta del frente.

Para parámetros positivos que cubren varios órdenes se aplicaron las mismas ecuaciones a $\log_{10} y_i$ y $\log_{10} \hat{y}_i$. También se calculó el error porcentual absoluto (APE, por sus siglas en inglés)

$$\text{APE}_i = 100 \frac{|\hat{y}_i - y_i|}{y_i}. \quad (14)$$

La mediana de APE describe un escenario típico y el percentil 90 indica el valor por debajo del cual se encuentra el 90 % de los escenarios. Por ejemplo, un percentil 90 de 65 % no significa que todos los errores sean 65 %; significa que aproximadamente una décima parte es mayor. ADR1D-ML usa una predicción agregada por cada uno de los 120 escenarios. La evaluación condicional de λ usa únicamente los 23 escenarios con verdad resoluble.

ADR1D-NN se resumió de dos maneras. Las métricas *agrupadas* usan los 299,880 puntos para describir el campo completo. Las métricas *por escenario* se calculan primero en cada malla de 2499 puntos y después resumen la distribución de 120 RMSE. Esta segunda lectura evita que un escenario con un campo sencillo o casi nulo determine por sí solo la conclusión.

3.3.2. Clasificación de resolubilidad

La matriz de confusión distingue verdaderos positivos (TP), verdaderos negativos (TN), falsos positivos (FP) y falsos negativos (FN). Se utilizaron

$$\text{Sens} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{Esp} = \frac{\text{TN}}{\text{TN} + \text{FP}}, \quad (15)$$

$$\text{BA} = \frac{1}{2}(\text{Sens} + \text{Esp}), \quad \text{Prec} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad (16)$$

$$F_1 = 2 \frac{\text{Prec Sens}}{\text{Prec} + \text{Sens}}. \quad (17)$$

La sensibilidad responde cuántos casos resolubles fueron recuperados; la precisión responde cuántas declaraciones positivas fueron correctas. La exactitud balanceada promedia sensibilidad y especificidad para no ocultar la clase minoritaria. El área bajo la curva ROC evalúa la ordenación de probabilidades a través de todos los umbrales, mientras que la matriz de confusión y F_1 dependen del umbral congelado 0.19. La pérdida logarítmica penaliza probabilidades seguras asignadas a la clase incorrecta. Estas métricas no son intercambiables: un clasificador puede ordenar bien los casos y, al mismo tiempo, generar demasiados falsos positivos en un umbral particular.

3.3.3. Diagnósticos físicos del campo neuronal

La región activa se definió mediante $c_{\text{ref}} > 10^{-4}$. Se reportaron MAE y RMSE tanto en todo el campo como en esa región, porque las zonas extensas con referencia cero o casi cero pueden reducir artificialmente el promedio global. Además se verificaron la condición inicial, la frontera de entrada y las fracciones de predicciones menores que cero o mayores que uno.

Para cada escenario se calculó primero la integral espacial

$$Q(t) = \int_0^L c(x, t) dx, \quad (18)$$

y después $\mathcal{M} = \int_0^T Q(t) dt$. El diagnóstico denominado *error relativo de masa integrada* es $|\hat{\mathcal{M}} - \mathcal{M}|/\mathcal{M}$. Como c está normalizada y el modelo no incluye área transversal, densidad aparente ni porosidad, esta cantidad es una integral comparativa del campo, no la masa dimensional total de contaminante en un acuífero.

El tiempo de llegada se definió, para cada posición interior donde la referencia alcanza 10^{-4} , como el primer tiempo tabulado que supera ese umbral. Se tomó el error absoluto entre las primeras llegadas de referencia y predicción y se resumió por escenario con la mediana espacial. Si la predicción nunca cruzó el umbral, se asignó como penalización el tiempo final más un paso temporal. Debido a que el campo se almacena cada 1800 s, este diagnóstico está cuantizado en intervalos de 1800 s. Finalmente, se aproximó en nodos interiores

$$r = \frac{\partial \hat{c}}{\partial t} - D_{\text{eff}} \frac{\partial^2 \hat{c}}{\partial x^2} + v_{\text{eff}} \frac{\partial \hat{c}}{\partial x} + \lambda \hat{c} \quad (19)$$

con diferencias centradas y se reportó su RMSE. Este residuo depende de la malla de diagnóstico, amplifica cambios bruscos y no está escrito en forma conservativa; por ello se registró sin umbral de aceptación.

3.3.4. Unidad independiente e intervalos

La unidad de remuestreo fue siempre el escenario base. Los intervalos del 95 % se calcularon con 5000 réplicas de remuestreo bootstrap percentil agrupado [8]. En cada réplica se muestrearon identificadores de escenario con reemplazo y se conservaron juntos sus cinco ruidos o sus 2499 puntos. Tratar cada punto como una observación independiente habría producido intervalos artificialmente estrechos, porque los valores vecinos pertenecen a una misma solución y están correlacionados.

Los criterios mínimos se fijaron antes de observar el desafío. Se eligieron como tolerancias de suficiencia para decidir si los modelos podían seguir usándose en experimentos ADR1D, no como límites regulatorios ni como garantías para un caso real. Los intervalos describen variación entre escenarios del diseño; tampoco representan intervalos predictivos para un escenario individual.

3.4. Referencia numérica tradicional

La referencia tradicional se implementó de forma separada de la generación analítica y de ADR1D-NN. Su propósito no fue competir en tiempo con la red, sino responder dos preguntas: si la solución cerrada es consistente con una discretización conservativa y si el error disminuye al refinar espacio y tiempo.

La Ecuación (2) puede escribirse como

$$\frac{\partial c}{\partial t} + \frac{\partial J}{\partial x} = -\lambda c, \quad J = v_{\text{eff}} c - D_{\text{eff}} \frac{\partial c}{\partial x}. \quad (20)$$

Se dividió el dominio en volúmenes de ancho uniforme Δx y se almacenó un promedio de concentración en el centro de cada celda. En una cara entre las celdas i e $i+1$, el flujo de Scharfetter–Gummel fue [7]

$$J_{i+1/2} = \frac{D_{\text{eff}}}{\Delta x} [B(-P_h)c_i - B(P_h)c_{i+1}], \quad P_h = \frac{v_{\text{eff}}\Delta x}{D_{\text{eff}}}, \quad (21)$$

donde $B(z) = z/(\exp z - 1)$ y $B(0) = 1$. Este ajuste reproduce difusión centrada cuando P_h es pequeño y evita las oscilaciones negativas que puede introducir una aproximación centrada convencional cuando la advección domina. La identidad $B(-P_h) - B(P_h) = P_h$ garantiza que un estado constante transporte el flujo advectivo correcto.

Después de ensamblar los flujos, el sistema semidiscreto toma la forma $d\mathbf{c}/dt = \mathbf{A}\mathbf{c} + \mathbf{b}_{\text{cin}}(t)$. Cada paso se resolvió con Euler hacia atrás:

$$(I - \Delta t A) \mathbf{c}^{n+1} = \mathbf{c}^n + \Delta t \mathbf{b} c_{\text{in}}(t_{n+1/2}). \quad (22)$$

El método es implícito y no requiere la restricción de estabilidad de un Euler explícito; no obstante, su precisión sí depende de Δt . Las factorizaciones se reutilizaron cuando se repitió el mismo paso temporal. Los instantes t_0 y $t_0 + \tau$ se insertaron exactamente en la malla para impedir que un paso atravesara un cambio de la fuente sin representarlo.

El dominio computacional se extendió a 1200 m. En la entrada se impuso el pulso de Dirichlet mediante una distancia de media celda. En la salida se fijó flujo difusivo nulo y se permitió el flujo advectivo $v_{\text{eff}} c$. La comparación se restringió a $0 \leq x \leq 900$ m para mantener al menos 300 m entre los puntos reportados y esa frontera artificial.

Se eligieron cuatro escenarios por régimen: Peclet mínimo, Peclet máximo, Danköehler máximo o mayor tiempo advectivo cuando $\lambda = 0$, y medoide del espacio paramétrico normalizado. El medoide es el escenario existente con menor distancia total respecto de los demás puntos de su régimen; a diferencia de un centroide, siempre corresponde a un caso real del conjunto. La selección no consultó errores de los modelos ni del solucionador. Las tres discretizaciones fueron

Nivel	Δx	Δt máximo
Grueso	10 m	225 s
Medio	5 m	112.5 s
Fino	2.5 m	56.25 s

Las tres mallas son anidadas. Para comparar niveles, los promedios de dos celdas finas adyacentes se restringieron a una celda del nivel siguiente; no se compararon centros desplazados mediante una interpolación arbitraria. La solución analítica se evaluó en los centros de celda y en los 49 tiempos de reporte. El orden empírico entre errores sucesivos se calculó como

$$p = \frac{\log(E_h/E_{h/2})}{\log 2}. \quad (23)$$

Como Δx y el paso temporal máximo se redujeron simultáneamente, p describe la campaña espacio-temporal conjunta y no el orden asintótico aislado de una sola discretización.

El balance se comprobó en cada paso mediante el cambio de la integral discreta, el flujo de salida, el flujo de entrada y la pérdida reactiva:

$$r_{\text{bal}} = \frac{M^{n+1} - M^n}{\Delta t} + J_{\text{out}} - J_{\text{in}} + \lambda M^{n+1}, \quad M^n = \Delta x \sum_i c_i^n. \quad (24)$$

La aceptación requirió, en cada uno de los 16 casos, RMSE de la malla fina frente a la analítica no mayor que 0.03, RMSE entre las mallas media y fina restringidas no mayor que 0.01 y concentración mínima no inferior a -10^{-10} . El balance discreto, el error máximo, el tiempo de llegada y el orden observado se conservaron como diagnósticos. El primer criterio mide acuerdo con una referencia externa a la malla; el segundo pregunta si dos resoluciones sucesivas ya son suficientemente cercanas bajo la tolerancia adoptada.

3.5. Costo computacional

El benchmark se ejecutó en CPU con un hilo computacional. Cada carga tuvo dos calentamientos y siete repeticiones medidas con `time.perf_counter_ns`; se reportaron mediana, rango intercuar-

tílico, mínimo y máximo. Los datos se cargaron en memoria antes de cronometrar los núcleos de cálculo, por lo que la lectura de CSV y la serialización de salidas quedaron fuera.

La separación por componentes evita atribuir todo el costo al modelo. La carga incluye verificar y deserializar el artefacto; la construcción de características transforma datos ya residentes en memoria; la inferencia llama al estimador congelado; y el recorrido de extremo a extremo reúne esos tres pasos, pero continúa excluyendo lectura y escritura de archivos. En la referencia tradicional se cronometraron por separado la evaluación analítica, la integración por volúmenes finitos y el recorrido que prepara los 16 casos y ejecuta ambos cálculos.

Los dos calentamientos permiten inicializar importaciones diferidas, cachés y rutas internas antes de resumir tiempos. Se conservan las siete mediciones en el JSON, de modo que la mediana no oculta su dispersión. El rango intercuartílico es la diferencia entre los percentiles 75 y 25 y describe la mitad central de las repeticiones.

Para no convertir la medición en una segunda consulta del desafío, los tiempos de los modelos se obtuvieron solo con la partición canónica publicada: 45 escenarios para ADR1D-ML y 112,455 puntos para ADR1D-NN. La evaluación analítica y el solucionador tradicional usaron los 16 casos seleccionados en malla fina, con 376,320 valores retenidos. Cada repetición produjo la misma salida. Un sondeo separado con `tracemalloc` describió asignaciones observables desde Python; no se interpreta como memoria residente total porque puede omitir asignaciones de bibliotecas nativas.

4. Resultados

4.1. Reproducción e integridad

ADR1D-ML reprodujo cinco arreglos de predicción y cuatro comprobaciones métricas sobre sus 45 escenarios canónicos. ADR1D-NN reprodujo 112,455 predicciones, 60 métricas escalares, 45 filas por escenario, cuatro selecciones diagnósticas y 4,455 restricciones físicas exactas. En ambos casos el informe reconstruido fue idéntico byte por byte al informe publicado.

La identidad binaria es una prueba más exigente que observar cifras parecidas: confirma que, con los mismos insumos y el mismo entorno, se conservaron el orden de registros, la precisión serializada y el contenido completo de los reportes. Esta prueba establece reproducibilidad de la evaluación canónica; no sustituye la prueba nueva, porque esos 45 escenarios ya habían intervenido en la historia de desarrollo.

La inferencia del desafío se ejecutó una sola vez por modelo después del bloqueo. No se realizó ajuste posterior. Una auditoría que no importó los módulos de evaluación ni cargó modelos recalculó la evidencia desde los CSV: completó 2664 comprobaciones, comparó 2423 valores y encontró una diferencia absoluta máxima de 8.92×10^{-13} , atribuible a la precisión de serialización. Los modelos, protocolos, entradas y resultados protegidos permanecieron sin cambios.

Las 2664 comprobaciones incluyeron conteos, identificadores, métricas globales, resultados por escenario, intervalos bootstrap, restricciones físicas y comprobaciones de integridad. La diferencia máxima es unas once órdenes de magnitud menor que el RMSE de los modelos; por ello refleja redondeo de archivos, no una discrepancia material entre el evaluador y el auditor.

4.2. Estimación de parámetros con ADR1D-ML

La Figura 1 muestra la agregación por escenario. La velocidad se recuperó con menor dispersión relativa que D_{eff} y λ . En los 120 escenarios, la mediana del error relativo absoluto de velocidad fue 3.95 %, su percentil 90 fue 10.87 % y el R^2 logarítmico fue 0.9892. Para dispersión, los valores correspondientes fueron 24.94 %, 65.81 % y 0.8494.




Figura 1: Validación de ADR1D-ML sobre 120 escenarios nuevos. (A–C) Acuerdo entre referencia y predicción agregada; la línea discontinua indica identidad. (D) Probabilidad de resolubilidad del decaimiento y umbral congelado. Cada punto representa un escenario base, no una realización individual de ruido.

En términos de distribución, la mitad de las estimaciones de velocidad se desvió menos de 3.95 % y nueve de cada diez se desviaron menos de 10.87 %. Para dispersión, la mitad quedó por debajo de 24.94 %, pero cerca de una décima parte superó 65.81 %. El cumplimiento de la tolerancia de dispersión no debe leerse como precisión uniforme: el protocolo aceptaba un error mayor para una propiedad más difícil de identificar a partir del ensanchamiento de curvas censuradas.

La clasificación produjo 82 verdaderos negativos, 15 falsos positivos, cuatro falsos negativos y 19 verdaderos positivos. La sensibilidad fue 0.8261, pero la precisión fue 0.5588. La especificidad fue 0.8454 y su promedio con la sensibilidad produce la exactitud balanceada de 0.8357. En otras palabras, el modelo recuperó 19 de los 23 casos resolubles, pero solo 19 de sus 34 declaraciones positivas fueron correctas. Este comportamiento puede ser razonable para una etapa de cribado si un falso negativo es más costoso, pero esa preferencia no fue parte del protocolo y no debe suponerse para una decisión concreta. Una clase positiva señala que conviene examinar el decaimiento; no lo confirma por sí sola.

La regresión condicional se evaluó en 23 escenarios, por encima del mínimo de diez fijado para aplicar el criterio. El intervalo bootstrap del 95 % para su mediana APE fue 16.59–38.93 %. Los intervalos correspondientes fueron 0.0255–0.0395 para el RMSE logarítmico de velocidad, 0.1524–0.1962 para el RMSE logarítmico de dispersión, 0.7418–0.9115 para exactitud balanceada y 0.8089–0.9856 para área ROC.

Tabla 5: Criterios principales de ADR1D-ML sobre el desafío bloqueado.

Métrica	Observado	Criterio	Evaluación
Mediana APE de v_{eff}	3.95 %	≤ 10 %	Cumple
Percentil 90 APE de v_{eff}	10.87 %	≤ 25 %	Cumple
$R^2_{\log_{10}}$ de v_{eff}	0.9892	≥ 0.90	Cumple
Mediana APE de D_{eff}	24.94 %	≤ 40 %	Cumple
Percentil 90 APE de D_{eff}	65.81 %	≤ 100 %	Cumple
$R^2_{\log_{10}}$ de D_{eff}	0.8494	≥ 0.50	Cumple
Exactitud balanceada de resolubilidad	0.8357	≥ 0.65	Cumple
Área ROC de resolubilidad	0.9113	≥ 0.70	Cumple
Mediana APE de λ condicional	22.51 %	≤ 85 %	Cumple
$R^2_{\log_{10}}$ de λ condicional	0.8139	≥ 0.10	Cumple

El ruido afectó de manera desigual las salidas. La mediana del coeficiente de variación entre réplicas fue 0.66 % para velocidad, 2.82 % para dispersión y 6.21 % para decaimiento condicional. El percentil 90 de la desviación estándar de la probabilidad fue 0.274, aun cuando la mediana fue 0.007. Por tanto, la estabilidad general de la clasificación no implica igual estabilidad probabilística cerca del umbral. Las cinco clases individuales coincidieron en 96 de los 120 escenarios; en los otros 24, al menos una réplica quedó del lado opuesto de 0.19. Conservar las cinco probabilidades permite ver esa sensibilidad que una única etiqueta agregada oculta.

Entre regímenes, la mediana APE de dispersión varió de 16.22 % en solo retardación a 30.73 % en solo decaimiento; el R^2 logarítmico permaneció entre 0.806 y 0.882. La velocidad fue más uniforme, con medianas APE entre 3.31 % y 4.07 %. La evidencia respalda mejor la estimación de velocidad que una lectura intercambiable de todas las salidas. En particular, no conviene propagar velocidad, dispersión y decaimiento hacia una simulación posterior como si compartieran el mismo error relativo.

4.3. Predicción de campos con ADR1D-NN

Sobre 299,880 puntos, ADR1D-NN obtuvo MAE de 0.00629, RMSE de 0.02258 y $R^2 = 0.98937$. En la región activa, el RMSE aumentó a 0.03887. La mediana del RMSE por escenario fue 0.01923, el percentil 90 fue 0.03100 y el máximo fue 0.05323. La Tabla 6 confirma el cumplimiento de los 12 criterios fijados.

Como la salida es $c = C/C_0$, el RMSE global corresponde a 2.26 puntos porcentuales de la concentración de entrada y el RMSE activo a 3.89 puntos. De los 299,880 puntos, 79,556 (26.5 %) pertenecieron a la región activa y 220,324 (73.5 %) a la región inactiva. Esta asimetría explica por qué se requiere una métrica activa además del promedio global.

Los intervalos bootstrap del 95 % fueron 0.02081–0.02447 para RMSE global, 0.03747–0.04047 para RMSE activo y 0.02630–0.03347 para el percentil 90 del RMSE por escenario. El error de masa mostró un comportamiento favorable en la mayoría de los casos, mientras que el error de llegada se concentró en 1800 s, igual al intervalo temporal de la tabla de evaluación. Este último resultado debe leerse con la resolución disponible: no demuestra precisión subintervalo. La mediana del error relativo de la integral espacio-temporal fue 1.74 %; en el 90 % de los escenarios no excedió 7.82 %. Esto indica buen acuerdo del contenido integrado, pero no garantiza que ese contenido esté situado en el mismo lugar o llegue en el mismo instante.

El caso A5-CH-0056 pertenece al régimen de solo decaimiento, fue un perfil de frontera y tuvo $Pe = 2.5$. Su RMSE fue 0.05323, $R^2 = 0.87276$, RMSE activo de 0.03662 y error máximo de 0.74876. La Figura 2 muestra que la diferencia se concentra alrededor de la evolución temprana

Tabla 6: Criterios principales de ADR1D-NN sobre el desafío bloqueado.

Métrica	Observado	Criterio	Evaluación
RMSE global	0.02258	≤ 0.035	Cumple
RMSE en región activa	0.03887	≤ 0.065	Cumple
R^2 global	0.98937	≥ 0.97	Cumple
Percentil 90 del RMSE por escenario	0.03100	≤ 0.05	Cumple
Mediana del error relativo de masa	1.74 %	≤ 10 %	Cumple
Percentil 90 del error relativo de masa	7.82 %	≤ 25 %	Cumple
Mediana del error de llegada	1800 s	≤ 1800 s	Cumple
Percentil 90 del error de llegada	1800 s	≤ 3600 s	Cumple
Predicciones negativas	0	$= 0$	Cumple
Predicciones mayores que uno	0	$= 0$	Cumple
Error máximo de condición inicial	0	$\leq 10^{-12}$	Cumple
Error máximo de frontera de entrada	0	$\leq 10^{-12}$	Cumple




Figura 2: Heterogeneidad del error de ADR1D-NN. (A) RMSE por escenario frente al número de Peclet; el criterio se aplica al percentil 90, no al máximo individual. (B–D) Referencia analítica, predicción congelada y error absoluto del escenario con mayor RMSE persistido, A5-CH-0056. Los cuadrados identifican perfiles de frontera y los círculos puntos Latin hypercube.

del pulso y su frente, no de manera uniforme en las 24 horas. El máximo error puntual de todo el desafío, 0.74945, apareció en otro perfil de frontera de Peclet 2.5, A5-CH-0026. La coexistencia de un RMSE global bajo y errores máximos altos se explica en parte por la gran proporción de celdas inactivas o cercanas a cero.

Los dos máximos permiten localizar el mecanismo. En A5-CH-0056 y A5-CH-0026, la fuente

comienza en $t = 1800$ s, la primera posición interior es $x = 20$ m y la referencia todavía vale cero en el instante exacto de encendido. La red predijo 0.74876 y 0.74945, respectivamente. El punto no está cubierto por las restricciones duras, porque no pertenece a $t = 0$ ni a $x = 0$. Se trata de una llegada interior anticipada en una discontinuidad temporal, no de una pequeña desviación distribuida por todo el campo. Además, como la referencia es menor que 10^{-4} , estos máximos pertenecen por definición a la región inactiva y no aparecen en el máximo activo.

Los perfiles de frontera tuvieron RMSE agrupado de 0.02995, frente a 0.02032 en los puntos Latin hypercube. El cuartil inferior de Peclet mostró RMSE agrupado de 0.03033, el mayor entre cuartiles. Sin embargo, el RMSE activo fue mayor en el cuartil superior de Peclet (0.05117), donde el frente ocupa menos puntos y los errores activos pesan menos en el promedio global. Estas dos observaciones aconsejan revisar tanto regiones activas como perfiles completos. También muestran que “mayor Peclet” no implica automáticamente mayor RMSE global: en el cuartil superior hay menos celdas activas y el promedio total queda dominado por ceros, aunque el error dentro del frente sea mayor.

No hubo valores fuera de $[0, 1]$. El residuo discreto de la EDP fue $1.961 \times 10^{-4} \text{ s}^{-1}$. Se reporta como diagnóstico: depende de la discretización usada para calcular derivadas y no equivale a una prueba de conservación local o de satisfacción exacta de la ecuación. Su valor tampoco se compara directamente con λ , porque el residuo reúne derivadas temporal, advectiva, dispersiva y reactiva, y las diferencias centradas son especialmente sensibles a los cambios bruscos del pulso.

4.4. Referencia numérica y refinamiento

La implementación analítica local se contrastó primero con 39,200 valores del campo bloqueado; la diferencia absoluta máxima fue 6.50×10^{-12} . Los 16 casos seleccionados se resolvieron en tres niveles, para 48 ejecuciones. El RMSE frente a la solución analítica disminuyó de forma monótona en todos los casos.




Figura 3: Referencia tradicional. (A) RMSE frente a la solución analítica al refinar espacio y tiempo. (B) RMSE de la malla fina en los 16 casos. (C) RMSE entre las mallas media y fina restringidas a puntos comunes. Los contornos rojos marcan los dos casos que rebasaron la tolerancia entre mallas.

La Tabla 8 abre el resultado agregado y permite revisar los 16 casos sin depender de la figura. “Medio–fino” compara promedios de celda en la misma malla restringida; los dos valores en negritas son los únicos que rebasan 0.01.

Catorce escenarios cumplieron todos los criterios. A5-CH-0117 (retardación con decaimiento) y A5-CH-0087 (solo retardación), ambos seleccionados por Peclet máximo y con $Pe = 350$, produjeron RMSE medio–fino de 0.01069 y 0.01074. Los excesos respecto de 0.01 fueron pequeños, pero se conservaron sin relajar el umbral. Los dos casos sí cumplieron la tolerancia fina frente a la solución

Tabla 7: Resumen de la referencia numérica tradicional.

Diagnóstico	Observado	Criterio	Evaluación
Mediana del RMSE fino	0.00546	≤ 0.03 por caso	Cumple
Máximo RMSE fino	0.01867	≤ 0.03 por caso	Cumple
Mediana del RMSE medio-fino	0.00399	≤ 0.01 por caso	—
Máximo RMSE medio-fino	0.01074	≤ 0.01 por caso	Evidencia mixta
Mínima concentración normalizada	0.0	$\geq -10^{-10}$	Cumple
Máximo residuo absoluto de balance	4.45×10^{-13}	Diagnóstico	—

Tabla 8: Resultados individuales de la referencia tradicional. Pe y Da se calculan con los parámetros verdaderos.

Caso	Criterio de selección	Pe	Da	RMSE fino	RMSE medio-fino
Conservativo					
A5-CH-0026	Pe mínimo	2.50	0	0.00554	0.00094
A5-CH-0027	Pe máximo	350.00	0	0.01867	0.00984
A5-CH-0025	Viaje advectivo máximo	50.00	0	0.00373	0.00363
A5-CH-0021	Medoide	31.48	0	0.00430	0.00389
Solo decaimiento					
A5-CH-0056	Pe mínimo	2.50	0.02828	0.00539	0.00094
A5-CH-0057	Pe máximo	350.00	0.00404	0.01863	0.00982
A5-CH-0043	Da máximo	74.42	0.13230	0.00649	0.00565
A5-CH-0053	Medoide	50.33	0.00441	0.00655	0.00514
Retardación y decaimiento					
A5-CH-0116	Pe mínimo	2.50	0.05798	0.00354	0.00073
A5-CH-0117	Pe máximo	350.00	0.00828	0.01697	0.01069
A5-CH-0119	Da máximo	44.72	0.30000	0.00226	0.00208
A5-CH-0110	Medoide	51.73	0.01751	0.00445	0.00408
Solo retardación					
A5-CH-0086	Pe mínimo	2.50	0	0.00368	0.00073
A5-CH-0087	Pe máximo	350.00	0	0.01704	0.01074
A5-CH-0085	Viaje advectivo máximo	50.00	0	0.00218	0.00223
A5-CH-0063	Medoide	58.58	0	0.00601	0.00509

analítica, con RMSE de 0.01697 y 0.01704.

Los excesos medio-fino fueron 6.9 % y 7.4 % respecto de la tolerancia, no órdenes de magnitud. Aun así, su coincidencia en $Pe = 350$ tiene una explicación numérica concreta. El Peclet de celda es $P_h = Pe \Delta x / L$: vale 1.75 en la malla media y 0.875 en la fina. Ambas soluciones permanecen estables y no negativas gracias al ajuste exponencial, pero representan un frente estrecho con resoluciones distintas. El criterio entre mallas detecta ese desplazamiento aunque las dos soluciones mantengan un RMSE menor que 0.03 frente a la analítica.

El mayor RMSE fino, 0.01867, correspondió al caso conservativo A5-CH-0027, también con $Pe = 350$. Este patrón es compatible con la mayor dificultad de resolver frentes dominados por advección a una resolución fija. El orden observado mediano fue 0.681 del nivel grueso al medio y 0.751 del medio al fino. Estos valores describen la campaña conjunta de Δx y Δt ; no constituyen una estimación asintótica formal del orden del esquema.

Todas las concentraciones fueron no negativas y el máximo residuo absoluto del balance discreto fue 4.45×10^{-13} ; el máximo residuo relativo fue 2.72×10^{-9} . La evidencia sostiene la coherencia de la referencia en los casos examinados, pero los dos incumplimientos entre mallas justifican el resultado agregado *evidencia mixta* y recomiendan refinamiento adicional cuando Peclet se acerca al extremo superior del dominio.

4.5. Costo computacional

La Figura 4 y la Tabla 9 presentan las medianas de siete repeticiones. Los intervalos intercuartílicos fueron estrechos respecto de las medianas y cada carga produjo una salida idéntica en los dos calentamientos, las siete repeticiones medidas y la sonda separada de memoria.




Figura 4: Costo computacional por componente. Las barras indican mediana y rango intercuartílico. Cada panel tiene una carga diferente y no debe usarse para calcular una aceleración directa entre modelos o métodos.

La inferencia pura de ADR1D-ML ocupó una fracción menor del tiempo total; la construcción de características y la verificación/carga tuvieron mayor peso. En ADR1D-NN ocurrió lo contrario: para 112,455 puntos, la inferencia dominó el tiempo y la construcción de entradas fue breve. En la referencia tradicional, la solución numérica dominó sobre la evaluación analítica.

Cada fila representa un lote completo, no el costo fijo de una predicción aislada. El rendimiento en escenarios o puntos por segundo resulta de dividir la cardinalidad del lote entre su tiempo mediano y puede cambiar con otro tamaño de lote. En un servicio que mantiene el modelo en memoria, el costo de carga se amortizaría; en una ejecución de línea de comandos que se inicia para cada

Tabla 9: Tiempos de pared en CPU con un hilo. IQR: rango intercuartílico.

Carga	Mediana (ms)	IQR (ms)	Rendimiento mediano
ADR1D-ML: verificar y cargar paquete	103.87	2.90	9.63 cargas s^{-1}
ADR1D-ML: construir 45 filas	99.41	3.02	452.7 escenarios s^{-1}
ADR1D-ML: inferir 45 escenarios	18.44	0.42	2441.0 escenarios s^{-1}
ADR1D-ML: extremo a extremo	229.54	23.17	196.0 escenarios s^{-1}
ADR1D-NN: verificar y cargar red	1.25	0.04	799.5 cargas s^{-1}
ADR1D-NN: construir 112,455 filas	9.55	1.11	1.177×10^7 puntos s^{-1}
ADR1D-NN: inferir 112,455 puntos	230.24	23.24	4.884×10^5 puntos s^{-1}
ADR1D-NN: extremo a extremo	256.23	20.80	4.389×10^5 puntos s^{-1}
Referencia analítica: 376,320 valores	21.50	0.75	1.750×10^7 valores s^{-1}
Solución tradicional: 376,320 valores	348.84	20.20	1.079×10^6 valores s^{-1}
Referencia numérica extremo a extremo	361.36	9.27	1.041×10^6 pares s^{-1}

consulta, volvería a pagarse. Este estudio informa ambos componentes, pero no simula un servicio persistente.

Estas cifras describen un equipo Apple arm64 con macOS 26.5.2, 10 CPU lógicas, 24 GiB de memoria y CPython 3.12.2. Se usaron NumPy 2.0.2, pandas 2.2.3, SciPy 1.15.2, scikit-learn 1.7.0, joblib 1.4.2 y PyTorch 2.7.1. Las cargas no son equivalentes: ADR1D-ML resuelve un problema inverso por escenario, ADR1D-NN evalúa un sustituto puntual y la referencia numérica conserva valores de 16 casos en una malla distinta. Por ello no se calcula un factor de aceleración.

La solución analítica fue la operación más rápida de las cargas de campo medidas. Esto importa para interpretar la utilidad del sustituto: en el problema homogéneo de ADR1D, donde existe una expresión cerrada, la red no ofrece una ventaja computacional demostrada frente a esa expresión. Su interés de integración debe evaluarse en problemas donde la solución cerrada deje de estar disponible o donde forme parte de un flujo más amplio. La campaña actual no mide todavía ese escenario.

El pico trazado desde Python fue aproximadamente 27.6 MiB para carga y flujo completo de ADR1D-ML, 25.9 MiB para el flujo completo de ADR1D-NN y 11.5 MiB para la referencia numérica completa. Estas cantidades excluyen memoria que las bibliotecas nativas no exponen a `tracemalloc`.

5. Discusión

5.1. Qué demuestra la evaluación

La principal fortaleza de la evidencia no es un único valor de R^2 , sino la secuencia de controles: modelos congelados, protocolo previo, desafío sin colisiones, una sola inferencia persistida, auditoría desde salidas planas, comparación por escenario y una referencia tradicional independiente. Dentro de ese marco, ADR1D-ML conserva capacidad para recuperar parámetros efectivos y ADR1D-NN reproduce campos con error agregado bajo.

Para ADR1D-ML, la velocidad es la salida más estable y precisa. La dispersión y el decaimiento contienen más variación relativa, lo cual concuerda con la dificultad de separar ensanchamiento, atenuación y censura a partir de seis curvas ruidosas. La clasificación de resolubilidad tiene buena discriminación, pero la precisión de 0.5588 impide tratar una clase positiva como confirmación de decaimiento. Su uso más razonable es señalar escenarios que requieren una estimación posterior o

información adicional.

Para ADR1D-NN, la ausencia de valores no físicos y el cumplimiento exacto de condiciones impuestas son propiedades útiles para integrarlo en un flujo numérico. Aun así, las restricciones duras cubren solo partes específicas del problema. El máximo error puntual y los perfiles de frontera muestran que una red puede satisfacer el contrato y conservar un RMSE global favorable mientras desplaza localmente un frente. Una validación destinada a máximos, tiempos de llegada o umbrales de concentración debe conservar diagnósticos locales.

La campaña tradicional respalda la referencia analítica en los 16 casos y confirma que el error disminuye al refinar. Los dos excesos entre mallas se concentran en Peclet máximo. No invalidan las demás comparaciones, pero sí marcan una condición concreta en la que la resolución media no puede tomarse como equivalente a la fina bajo la tolerancia adoptada.

5.2. Lectura conjunta de los modelos

Aunque ADR1D-ML y ADR1D-NN pueden ocupar etapas consecutivas de un flujo de trabajo, esta campaña los validó por separado. ADR1D-ML recibió sensores y se comparó con parámetros verdaderos. ADR1D-NN recibió directamente los parámetros verdaderos del desafío, no las estimaciones de ADR1D-ML. Por tanto, el RMSE de la red cuantifica su error como sustituto cuando sus entradas físicas son conocidas; no incluye el error de un problema inverso previo.

Esta distinción tiene consecuencias. Si una dispersión estimada con error de 25 % se entrega a la red, el campo resultante puede diferir de la solución calculada con la dispersión verdadera aun cuando ADR1D-NN aproxime perfectamente la entrada recibida. Del mismo modo, un falso positivo de resolubilidad puede introducir un λ positivo en un caso cuya atenuación no puede separarse del ruido. Los errores de ambas etapas no tienen por qué sumarse linealmente y pueden cambiar tiempos de llegada, amplitudes y áreas de maneras distintas.

En consecuencia, la evidencia actual permite integrar las interfaces en experimentos controlados, pero no permite asignar al flujo encadenado las métricas individuales de cualquiera de los modelos. Una validación de extremo a extremo tendría que tomar las cinco realizaciones de sensores, propagar la distribución de parámetros estimados por ADR1D-ML a ADR1D-NN y comparar los campos resultantes con la referencia, sin sustituir las entradas por sus valores verdaderos.

5.3. Qué no demuestra

Los escenarios nuevos pertenecen a la misma ecuación, geometría y familia de fuentes que el benchmark de desarrollo. Son una muestra independiente dentro del dominio, no una prueba de física distinta. La validación tampoco aporta datos de campo con velocidad hidráulica, dispersión, porosidad y condiciones de frontera simultáneamente observadas. Los registros WQP disponibles ofrecen contexto de concentraciones, unidades, censura y procedencia, pero no permiten reconstruir por sí solos un caso identificable de la Ecuación (1).

Los intervalos bootstrap cuantifican variación entre escenarios del diseño, no incertidumbre predictiva para un caso individual. ADR1D-NN es determinista y no se evaluaron ensambles, calibración probabilística ni propagación de incertidumbre paramétrica. Tampoco se ensayó extrapolación espacial, temporal o paramétrica.

La comparación de tiempos no separa todas las decisiones de implementación ni representa otro hardware. En particular, cargar un bundle de árboles y cargar un checkpoint neuronal no tienen el mismo contrato. Los rendimientos por segundo son útiles para dimensionar esta ejecución, pero no deben generalizarse sin repetir el benchmark en el entorno objetivo.

La Tabla 10 resume las fronteras de interpretación.

Tabla 10: Afirmaciones respaldadas y no respaldadas por la campaña.

Pregunta	Respuesta	Razón
¿Se reproducen las evaluaciones canónicas?	Sí	Los reportes reconstruidos fueron idénticos byte por byte.
¿Funcionan los modelos por separado en casos nuevos dentro de ADR1D?	Sí, con límites	Cumplieron los criterios agregados, pero conservaron falsos positivos y errores locales grandes.
¿Está validado el encadenamiento ADR1D-ML $\rightarrow$ ADR1D-NN?	No	La red recibió parámetros verdaderos, no parámetros inferidos.
¿Está validado el uso con datos de campo?	No	Faltan parámetros hidráulicos, condiciones de frontera y una referencia observacional identificable.
¿Está demostrada la extrapolación?	No	Todos los casos pertenecen a los rangos, la geometría y la ecuación de ADR1D.
¿Existe una aceleración universal?	No	Las cargas, cardinalidades y equipos no son equivalentes; la solución analítica fue además más rápida en este caso.
¿Los criterios equivalen a seguridad regulatoria?	No	Son tolerancias de ingeniería fijadas para el benchmark sintético.

5.4. Implicaciones para integración numérica

Los resultados apoyan una integración condicionada, no una sustitución automática del modelo físico. Se recomienda:

1. **Verificar identidad.** Comprobar el modelo, el protocolo y los módulos de inferencia contra sus manifiestos antes de cargar un artefacto evita evaluar una versión distinta de la documentada.
2. **Validar entradas.** Rechazar o marcar posiciones, tiempos, parámetros y pulsos fuera de los rangos ADR1D. Una salida numéricamente válida no convierte una extrapolación en evidencia.
3. **Conservar las réplicas.** En el problema inverso, mantener las cinco predicciones y la probabilidad de resolubilidad, no solo sus promedios y clases, para representar sensibilidad al ruido.
4. **Propagar parámetros.** Si ADR1D-ML alimenta a ADR1D-NN, evaluar varios conjuntos plausibles de parámetros en vez de tratar una estimación puntual como verdad exacta.
5. **Revisar el campo local.** Acompañar RMSE global con error en región activa, llegada, perfiles cerca de la fuente y máximos. Los dos errores cercanos a 0.75 muestran por qué este paso es necesario.
6. **Mantener casos centinela.** Resolver con referencia analítica o numérica combinaciones de frontera y Peclet alto en cada versión del flujo integrado.
7. **Registrar costo por componente.** Separar carga, transformación e inferencia en el hardware de destino antes de elegir una estrategia de despliegue.
8. **Revalidar al cambiar la física.** Heterogeneidad, otras fronteras, una geometría multidimensional o datos de sitio constituyen un problema nuevo y requieren protocolo y evidencia nuevos.

En simulaciones repetidas, ADR1D-NN puede ser útil como aproximador del campo y ADR1D-ML como etapa inversa preliminar. Ninguno de los dos sustituye la revisión de identificabilidad, la propagación de incertidumbre o el balance físico que requiera la aplicación final.

6. Amenazas a la validez y limitaciones

- **Validez externa.** El estudio es sintético, unidimensional y homogéneo. No cubre heterogeneidad espacial, transporte multidimensional, reacciones no lineales ni datos de campo completos.
- **Independencia física.** El desafío usa una implementación reconstruida de la misma solución analítica y los mismos rangos físicos. La independencia proviene de las muestras, el bloqueo y la auditoría, no de una teoría de transporte diferente.
- **Dependencia entre benchmark y modelos.** Tanto las etiquetas de desarrollo como las del desafío proceden de ADR1D. La ausencia de colisiones evita repetir escenarios, pero no elimina supuestos compartidos sobre homogeneidad, linealidad, pulso rectangular y parámetros constantes.
- **Referencia tradicional.** Se evaluaron 16 casos y tres mallas. Esta selección cubre extremos y medoides, pero no constituye un barrido exhaustivo de convergencia.
- **Resolución temporal.** Los diagnósticos de llegada usan pasos de 1800 s en el campo de desafío; errores iguales a ese valor están cuantizados por la tabla de evaluación.
- **Ruido.** El modelo de sensores representa una sola combinación de error gaussiano, piso absoluto, censura y sustitución. No cubre deriva, dependencia temporal, sesgo de calibración o fallas de sensores.
- **Decaimiento condicional.** La regresión de λ se resume con 23 escenarios resolubles. Sus intervalos son más amplios que los de velocidad y deben conservarse al comunicar precisión.
- **Definición de resolubilidad.** El umbral $1 - \exp(-Da) \geq 0.03$ relaciona atenuación ideal y ruido relativo, pero no incorpora el piso absoluto, la censura ni todas las correlaciones entre parámetros. Es una definición operativa del benchmark, no un límite universal de detectabilidad experimental.
- **Acoplamiento no evaluado.** ADR1D-NN recibió parámetros verdaderos. El estudio no cuantifica cómo se propagan hacia el campo los errores y decisiones de ADR1D-ML.
- **Discontinuidades.** La fuente rectangular cambia de forma instantánea. Los mayores errores neuronales aparecen precisamente junto al encendido y la primera celda interior; otras formas de fuente podrían cambiar la distribución del error.
- **Memoria y tiempo.** El benchmark se realizó en una máquina. La sonda de memoria de Python puede omitir asignaciones nativas y no equivale a memoria residente máxima.
- **Criterios.** Las tolerancias fueron fijadas antes del desafío, pero son criterios de ingeniería para este estudio, no estándares de calidad de agua ni garantías para decisiones públicas.

7. Reproducibilidad y trazabilidad

Todos los resultados se almacenaron en formatos abiertos CSV o JSON. El protocolo legible por máquina se encuentra en `configs/validation_protocol.json`. La evidencia principal se ubica en `results/`; los generadores y validadores están en `src/`. Solo `src/evaluate_locked_challenge.py` ejecutó inferencia nueva sobre el desafío, una vez por modelo. La generación posterior de figuras leyó exclusivamente resultados persistidos y dejó constancia de `model_loading_or_inference = false`.

La reproducibilidad se organizó en tres alcances. La *verificación de integridad* confirma que cada archivo esperado existe y corresponde al registro machine-readable. La *auditoría de resultados* vuelve a calcular métricas e intervalos desde predicciones persistidas, sin consultar los modelos. La

reconstrucción completa vuelve a generar casos o ejecutar modelos y debe hacerse en un directorio temporal para no confundir una réplica con la evidencia histórica. El manifiesto final utiliza los dos primeros alcances; no incrementa el contador de inferencias del desafío.

Las rutas almacenadas en los manifiestos son relativas a la carpeta de la validación, de modo que el conjunto puede moverse a otra computadora sin reescribir rutas absolutas. Cada JSON registra versiones, semillas, conteos e información de integridad de sus insumos. Las huellas criptográficas empleadas por los validadores permanecen en esos archivos y no se duplican en el informe.

Tabla 11: Registros principales de trazabilidad y contenido documentado.

Artefacto	Estado o contenido
<code>validation_protocol.json</code>	Protocolo bloqueado
<code>challenge_scenarios.csv</code>	120 escenarios
<code>challenge_analytical_field.csv</code>	299,880 valores
<code>challenge_sensor_observations.csv</code>	176,400 observaciones
<code>canonical_reproduction.json</code>	Reproducción completa
<code>challenge_result_validation.json</code>	Auditoría aprobada
<code>numerical_reference_cases.csv</code>	48 ejecuciones
<code>numerical_reference_metrics.json</code>	Evidencia mixta
<code>computational_cost.json</code>	11 cargas medidas
<code>figure_manifest.json</code>	Ocho archivos gráficos

Los cuatro gráficos se almacenan en PDF y PNG. Dos renderizaciones temporales independientes produjeron archivos idénticos en los ocho formatos. El manifiesto registra los insumos, el generador y cada figura, así como el criterio que seleccionó A5-CH-0056 para la inspección de campo.

La auditoría del costo verificó 14 artefactos antes y después, sin cambios, y registró cero inferencias de desafío y cero predicciones nuevas persistidas. El reporte de costo reprodujo además los resultados canónicos de ambos modelos y los RMSE de la referencia numérica dentro de tolerancias menores que 10^{-12} .

El informe también forma parte de la trazabilidad. La fecha interna y el identificador del remolque PDF se fijaron antes de compilar; dos construcciones en carpetas separadas deben producir el mismo archivo binario. Esta condición comprueba que el documento entregado corresponde al fuente LaTeX y a las figuras registradas, no que los resultados científicos sean correctos por el solo hecho de compilar.

8. Conclusiones

La validación permite formular siete conclusiones delimitadas:

1. ADR1D-ML reprodujo sus resultados canónicos y cumplió todos los criterios del desafío. La estimación de velocidad fue la salida más sólida; dispersión y decaimiento conservaron mayor incertidumbre relativa.
2. La clasificación de resolubilidad distinguió adecuadamente las clases en conjunto, pero produjo 15 falsos positivos y una precisión de 0.5588. La probabilidad y el contexto de uso deben acompañar cualquier clase positiva.
3. ADR1D-NN obtuvo buen ajuste global, conservó el intervalo físico e impuso exactamente las condiciones duras. Los errores máximos cercanos a 0.75 y el peor RMSE de 0.05323 muestran que el resumen global no reemplaza el análisis de frentes y perfiles de frontera.

4. La solución tradicional concordó con la analítica y mejoró monótonamente en los 16 casos. Dos escenarios de Peclet 350 no cumplieron la tolerancia medio-fino; el resultado numérico agregados, por diseño, evidencia mixta.
5. Los tiempos observados muestran que ambos modelos pueden evaluarse en fracciones de segundo para las cargas ensayadas. Las diferencias de tarea, malla y cardinalidad impiden convertir esas mediciones en una aceleración universal.
6. Los dos modelos se validaron por separado. ADR1D-NN recibió parámetros verdaderos, de modo que sus métricas no describen un flujo alimentado por ADR1D-ML. La propagación del error inverso hacia el campo sigue pendiente de una evaluación específica.
7. Los modelos están listos para integrarse en experimentos numéricos controlados dentro del dominio ADR1D, con verificación de entradas, conservación de réplicas y controles físicos. La evidencia no autoriza extrapolación, validación de campo ni uso regulatorio sin una campaña adicional.

El siguiente paso inmediato es evaluar el encadenamiento completo dentro del mismo dominio: sensores con ruido, parámetros inferidos, campo neuronal y comparación final con la referencia. Después podrá estudiarse cuánto cambia la evidencia al introducir heterogeneidad, condiciones de frontera distintas y datos observacionales suficientes para identificar el problema físico. Cada ampliación debe conservar el mismo orden: protocolo previo, artefactos congelados, métricas locales y publicación de resultados favorables y desfavorables.

Declaraciones

Contribuciones de autoría. Gerardo Tinoco-Guerrero, Francisco J. Domínguez-Mota y J. Alberto Guzmán-Torres contribuyeron en igual medida al diseño, análisis, interpretación y revisión del trabajo.

Conflictos de interés. Los autores declaran que no existen conflictos de interés.

Financiamiento y respaldo institucional. Este trabajo recibió financiamiento y respaldo institucional de la Secretaría de Ciencias, Humanidades, Tecnología e Innovación (SECIHTI) de México; la Coordinación de la Investigación Científica de la Universidad Michoacana de San Nicolás de Hidalgo (CIC-UMSNH); SIIIA MATH: Soluciones en Ingeniería; el International Centre for Numerical Methods in Engineering (CIMNE); y Aula CIMNE Morelia.

Disponibilidad de datos y código. Los datos ADR1D originales están disponibles en <https://github.com/gstinoco/ADR1D>. Los modelos se publican en <https://github.com/gstinoco/ADR1D-ML> y <https://github.com/gstinoco/ADR1D-NN>. La evidencia específica de esta validación se conserva junto con este informe en archivos CSV, JSON, PDF y Python legibles y auditables.

Referencias

- [1] G. Tinoco-Guerrero, F. J. Domínguez-Mota y J. A. Guzmán-Torres, *ADR1D: A Reproducible One-Dimensional Contaminant-Transport Benchmark*, versión 1.0.0, Universidad Michoacana de San Nicolás de Hidalgo, 2026. <https://github.com/gstinoco/ADR1D>.
- [2] G. Tinoco-Guerrero, F. J. Domínguez-Mota y J. A. Guzmán-Torres, *ADR1D-ML: Identifiable Parameter Inference for One-Dimensional Reactive Transport*, versión 1.0.0, Universidad Michoacana de San Nicolás de Hidalgo, 2026. <https://github.com/gstinoco/ADR1D-ML>.
- [3] G. Tinoco-Guerrero, F. J. Domínguez-Mota y J. A. Guzmán-Torres, *ADR1D-NN: A Physics-Constrained Neural Surrogate for One-Dimensional Reactive Transport*, versión 1.0.0, Universidad Michoacana de San Nicolás de Hidalgo, 2026. <https://github.com/gstinoco/ADR1D-NN>.
- [4] A. Ogata y R. B. Banks, *A Solution of the Differential Equation of Longitudinal Dispersion in Porous Media*, U.S. Geological Survey Professional Paper 411-A, 1961. <https://doi.org/10.3133/pp411A>.
- [5] J.-S. Chen y C.-W. Liu, “Generalized analytical solution for advection-dispersion equation in finite spatial domain with arbitrary time-dependent inlet boundary condition,” *Hydrology and Earth System Sciences*, vol. 15, pp. 2471–2479, 2011. <https://doi.org/10.5194/hess-15-2471-2011>.
- [6] M. D. McKay, R. J. Beckman y W. J. Conover, “A comparison of three methods for selecting values of input variables in the analysis of output from a computer code,” *Technometrics*, vol. 21, no. 2, pp. 239–245, 1979. <https://doi.org/10.1080/00401706.1979.10489755>.
- [7] D. L. Scharfetter y H. K. Gummel, “Large-signal analysis of a silicon Read diode oscillator,” *IEEE Transactions on Electron Devices*, vol. 16, no. 1, pp. 64–77, 1969. <https://doi.org/10.1109/T-ED.1969.16566>.
- [8] B. Efron y R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall/CRC, 1993.